Exercícios Deep Learning - List Teórica 01 Elaboração de Carolina Coimbra, Guilherme Borges e Edemir Andrade Jr.

August 23, 2019

1 Retas

1- Esboce num gráfico as seguintes retas:


a)
$$2x_2 + x_1 = 0$$

b)
$$x_2 - 2x_1 + 1 = 0$$

c)
$$x_2 - 1 = 0$$

d)
$$x_1 - 1 = 0$$

 ${\bf 2}\text{-}$ Especifique uma reta que divide as duas categorias de itens no gráfico abaixo onde x_1 é o eixo abscissas e e x_2 é o eixo das ordenadas.



3- Considere a reta $x_2 = 3 + 2x_1$. Obtenha a expressão analítica do conjunto de todas as retas paralelas e o conjunto de todas as retas perpendiculares à reta acima.

2 Álgebra Linear

4- Sejam $w=w_1,...w_n$ e $x=x_1,...,x_n$ vetores coluna de dimensão $n\times 1$. Expresse w'x em termos de um somatório.

5- Seja $x = (x_1, ..., x_n)$ um vetor-coluna $n \times 1$ e A uma matriz $n \times n$. A' indica a matriz transposta de A. Verifique que as seguintes identidades matriciais estão corretas, checando se o lado direito é igual ao lado esquerdo.

a)
$$x'Ax = \sum_{i,j} x_i x_j A_{ij}$$

b)
$$x'x = \sum_{i} x_{i}^{2}$$

c) xx' é uma matriz simétrica $n \times n$ com elemento (i, j) dado por x_ix_j

3 Derivadas

6- Encontre a derivada F'(x) de

$$F(x) = \sqrt{x^2 + 1}$$

7- Encontre a derivada F'(x) de

$$F(x) = e^{\sin x}$$

8- Função sigmóide:

$$S(x) = \frac{1}{1 + e^{-x}}$$

- a) Esboce o gráfico de S(x).
- **b)** Mostre que S(-x) = 1 S(x)

c) Calcule a derivada em termos da própria sigmóide, isto é, mostre que S'(x) = S(x)(1 - S(x)). Esboce o gráfico da derivada.

d) Qual o valor máximo de S'(x)? Para qual valor de x ela atinge esse máximo?


e) Considere
$$S(z) = \frac{1}{1+e^{-z}}$$
, sendo que $z = b + W_1 x$ encontre $\frac{\partial S}{\partial b}$ e $\frac{\partial S}{\partial W_1}$.

f) Considere $S(h(x)) = \frac{1}{1+e^{-h(x)}}$, calcule $\frac{\partial S}{\partial x}$ em função de h(x).

9- Suponha que você tenha dados da forma $\mathbf{X} = (X_1, X_2, ..., X_n)$, onde $X_i \in \mathbb{R}$ e que seu classificador seja da forma $\hat{Y}_i = \beta X_i$. Considerando o erro quadrático, ou seja, $L(\hat{Y}, Y) = \sum_{i=1}^n (\hat{Y}_i - Y_i)^2$, qual o valor de β que minimiza o erro?

4 Perceptron

- 10- Considere um perceptron com duas features x_1, x_2 , onde $w_0 = 3, w_1 = 2, w_2 = 1$, qual é a fórmula da reta que divide as duas classes? Qual é o vetor normal à reta?
- 11- Considere um perceptron com $w_0 = 0, w_1 = -1, w_2 = 1$, com os pontos mostrados no gráfico abaixo (círculos pertencem à classe 1 e 'x' à classe 0), esboce o gráfico da reta de separação das classes. Execute uma iteração do algoritmo do perceptron com m = 0.1, esboce a nova reta de separação.



12- Seja o conjunto de entrada dado por um total de 4 amostras, onde cada amostra é representada pela tupla (x_i, t) , composta pelo vetor $x_i = (x_0, x_1, x_2)$ e um rotulo t associado a amostra.

	x_0	x_1	x_2	t
Entrada 1	1	0	0	0
Entrada 2	1	0	1	0
Entrada 3	1	1	0	0
Entrada 4	1	1	1	1

a) Execute a quinta iteração do algoritmo do perceptron com pesos iniciais $w_0, w_1 e w_2$ iguais a 0, taxa de aprendizado η igual a 0.5, e utilizando a função de ativação degrau bipolar definida como:

$$f(x) = \begin{cases} -1 & \text{se } x < 0 \\ +1 & \text{se } x \ge 0 \end{cases}$$

Abaixo segue o exemplo das quatro primeiras iterações do algoritmo:

1º Iteração:

Entrada 1:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(0 * 1 + 0 * 0 + 0 * 0) = f(0) = 0$; $logo s_{out} = t$ (1)

Entrada 2:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(0 * 1 + 0 * 0 + 0 * 1) = f(0) = 0$; $logo s_{out} = t$ (2)

Entrada 3:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(0 * 1 + 0 * 1 + 0 * 0) = f(0) = 0$; $logo s_{out} = t$ (3)

Entrada 4:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(0 * 1 + 0 * 1 + 0 * 1) = f(0) = 0$; $logo s_{out} \neq t$ (4)

Atualiza Pesos:

$$w_0 = w_0 + \eta(t - s_{out}) * x_0 = 0 + 0.5(1 - 0) * 1 = 0.5$$

$$w_1 = w_1 + \eta(t - s_{out}) * x_1 = 0 + 0.5(1 - 0) * 1 = 0.5$$

$$w_2 = w_2 + \eta(t - s_{out}) * x_2 = 0 + 0.5(1 - 0) * 1 = 0.5$$

2º Iteração:

Entrada 1:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(0.5 * 1 + 0.5 * 0 + 0.5 * 0) = f(0.5) = 1; logo s_{out} \neq t$ (5)

Atualiza Pesos:

$$w_0 = w_0 + \eta(t - s_{out}) * x_0 = 0.5 + 0.5(0 - 1) * 1 = 0$$

$$w_1 = w_1 + \eta(t - s_{out}) * x_1 = 0.5 + 0.5(0 - 1) * 0 = 0.5$$

$$w_2 = w_2 + \eta(t - s_{out}) * x_2 = 0.5 + 0.5(0 - 1) * 0 = 0.5$$

Entrada 2:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(0 * 1 + 0.5 * 0 + 0.5 * 1) = f(0.5) = 1; logo s_{out} \neq t$ (6)

Atualiza Pesos:

$$w_0 = w_0 + \eta(t - s_{out}) * x_0 = 0 + 0.5(0 - 1) * 1 = -0.5$$

$$w_1 = w_1 + \eta(t - s_{out}) * x_1 = 0.5 + 0.5(0 - 1) * 0 = 0.5$$

$$w_2 = w_2 + \eta(t - s_{out}) * x_2 = 0.5 + 0.5(0 - 1) * 1 = 0$$

Entrada 3:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(-0.5 * 1 + 0.5 * 1 + 0 * 0) = f(0) = 0; logo s_{out} = t$ (7)

Entrada 4:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(-0.5 * 1 + 0.5 * 1 + 0 * 1) = f(0) = 0; logo s_{out} \neq t$ (8)

Atualiza Pesos:

$$w_0 = w_0 + \eta(t - s_{out}) * x_0 = -0.5 + 0.5(1 - 0) * 1 = 0$$

$$w_1 = w_1 + \eta(t - s_{out}) * x_1 = 0.5 + 0.5(1 - 0) * 1 = 1$$

$$w_2 = w_2 + \eta(t - s_{out}) * x_2 = 0 + 0.5(1 - 0) * 1 = 0.5$$

3º Iteração:

Entrada 1:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(0 * 1 + 1 * 0 + 0.5 * 0) = f(0) = 0; logo s_{out} = t$ (9)

Entrada 2:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(0 * 1 + 1 * 0 + 0.5 * 1) = f(0.5) = 1; logo s_{out} \neq t$ (10)

Atualiza Pesos:

$$w_0 = w_0 + \eta(t - s_{out}) * x_0 = 0 + 0.5(0 - 1) * 1 = -0.5$$

$$w_1 = w_1 + \eta(t - s_{out}) * x_1 = 1 + 0.5(0 - 1) * 0 = 1$$

$$w_2 = w_2 + \eta(t - s_{out}) * x_2 = 0.5 + 0.5(0 - 1) * 1 = 0$$

Entrada 3:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(-0.5 * 1 + 1 * 1 + 0 * 0) = f(0.5) = 1; logo s_{out} \neq = t$ (11)

Atualiza Pesos:

$$w_0 = w_0 + \eta(t - s_{out}) * x_0 = -0.5 + 0.5(0 - 1) * 1 = -1$$

$$w_1 = w_1 + \eta(t - s_{out}) * x_1 = 1 + 0.5(0 - 1) * 0 = 1$$

$$w_2 = w_2 + \eta(t - s_{out}) * x_2 = 0.5 + 0.5(0 - 1) * 1 = 0$$

Entrada 4:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(-1 * 1 + 1 * 1 + 0 * 1) = f(0) = 0; logo s_{out} \neq t$ (12)

Atualiza Pesos:

$$w_0 = w_0 + \eta(t - s_{out}) * x_0 = -1 + 0.5(1 - 0) * 1 = -0.5$$

$$w_1 = w_1 + \eta(t - s_{out}) * x_1 = 1 + 0.5(1 - 0) * 1 = 1.5$$

$$w_2 = w_2 + \eta(t - s_{out}) * x_2 = 0 + 0.5(1 - 0) * 1 = 0.5$$

4º Iteração:

Entrada 1:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(-0.5 * 1 + 1.5 * 0 + 0.5 * 0) = f(-0.5) = 0; logo s_{out} = t$ (13)

Entrada 2:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(-0.5 * 1 + 1.5 * 0 + 0.5 * 1) = f(0) = 0; logo s_{out} = t$ (14)

Entrada 3:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(-0.5 * 1 + 1.5 * 1 + 0.5 * 0) = f(1) = 1; logo s_{out} \neq = t$ (15)

Atualiza Pesos:

$$w_0 = w_0 + \eta(t - s_{out}) * x_0 = -0.5 + 0.5(0 - 1) * 1 = -1$$

$$w_1 = w_1 + \eta(t - s_{out}) * x_1 = 1.5 + 0.5(0 - 1) * 0 = 1$$

$$w_2 = w_2 + \eta(t - s_{out}) * x_2 = 0.5 + 0.5(0 - 1) * 1 = 0.5$$


Entrada 4:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(-1 * 1 + 1 * 1 + 0.5 * 1) = f(0.5) = 1; logo s_{out} = t$ (16)

b) Esboce o gráfico da reta gerada após a quinta iteração do algoritmo. A equação da reta após a quinta iteração é dado pela equação: $x_1w_1+x_2w_2=-w_0$

Solução



2-
$$x_2 - \frac{1}{2}x_1 = 0$$

- 3- Paralelas : $x_2=2x_1+c$ com $c\in\mathbb{R}$ Perpendiculares: $x_2=-\frac{1}{2}x_1+c$ com $c\in\mathbb{R}$
- $4-\sum_{i=1}^n w_i x_i$
- 5- a)

$$\mathbf{x'Ax} = \begin{bmatrix} \sum_{j} x_1 A_{1,j} & \cdots & \sum_{j} x_n A_{n,j} \end{bmatrix} \mathbf{x}$$
$$= \sum_{i,j} x_i A_{i,j} x_j$$

b)


$$\mathbf{x'x} = \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$
$$= \sum_i x_i^2$$

c)

$$\mathbf{x}\mathbf{x'} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix}$$

$$= \begin{bmatrix} x_1x_1 & x_1x_2 & \cdots & x_1x_n \\ x_2x_1 & x_2x_2 & \cdots & x_2x_n \\ \vdots & \vdots & \ddots & \vdots \\ x_nx_1 & x_nx_2 & \cdots & x_nx_n \end{bmatrix}$$


- **6-** $x(x^2+1)^{-\frac{1}{2}}$
- 7- $\cos x e^{\sin x}$
- 8- a)



b)
$$S(-x) = \frac{1}{1+e^x} = \frac{1}{1+\frac{1}{e^{-x}}} = \frac{1}{\frac{e^{-x}+1}{e^{-x}}} = \frac{e^{-x}}{e^{-x}+1} = 1 - \frac{1}{1+e^{-x}} = 1 - S(x)$$

c) $S'(x) = \frac{e^{-x}}{(1+e^{-x})^2} = \frac{1}{1+e^{-x}} \frac{e^{-x}}{1+e^{-x}} = S(x)(1 - S(x))$

c)
$$S'(x) = \frac{e^{-x}}{(1+e^{-x})^2} = \frac{1}{1+e^{-x}} \frac{e^{-x}}{1+e^{-x}} = S(x)(1-S(x))$$



d) Valor máximo é 0.25 quando
$$x = 0$$
.
e) $\frac{\partial S}{\partial b} = \frac{e^{-(b+W_1x)}}{(1+e^{-(b+W_1x)})^2}$ e $\frac{\partial S}{\partial W_1} = \frac{xe^{-(b+W_1x)}}{(1+e^{-(b+W_1x)})^2}$
f) $\frac{\partial S}{\partial x} = \frac{h'(x)e^{-h(x)}}{(1+e^{-h(x)})^2}$

f)
$$\frac{\partial S}{\partial x} = \frac{h'(x)e^{-h(x)}}{(1+e^{-h(x)})^2}$$

9- Para encontrar o valor mínimo da perda, devemos derivar a função em

relação a
$$\beta$$
 e encontrar or valor infinition da perda, deventos derivar relação a β e encontrar onde ela é 0. $L(\hat{Y},Y) = \sum_{i=1}^{n} (\beta X_i - Y_i)^2$
$$\frac{\partial L}{\partial \beta} = \sum_{i=1}^{n} 2X_i(\beta X_i - Y_i) = 2(\sum_{i=1}^{n} \beta X_i^2 - \sum_{i=1}^{n} X_i Y_i) = 0$$

$$\beta = \frac{\sum_{i=1}^{n} X_i Y_i}{\sum_{i=1}^{n} X_i^2}$$

10- Reta: $x_2 = -3 - 2x_1$ Vetor normal: (2 1)


11- Reta: $x_2 = x_1$

Algoritmo:

O único ponto onde $y \neq \hat{y}$ é (2,3)

$$\begin{bmatrix} w_0 \\ w_1 \\ w_2 \end{bmatrix} = \begin{bmatrix} 0 \\ -1 \\ 1 \end{bmatrix} + 0.1(-1) \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = \begin{bmatrix} -0.1 \\ -1.2 \\ 0.7 \end{bmatrix}$$

Nova reta : $x_2 = \frac{1}{7} + \frac{12}{7}x_1$



a)

5º Iteração:

Entrada 1:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(-1 * 1 + 1 * 0 + 0.5 * 0) = f(-1) = 0; logo s_{out} = t$ (17)

Entrada 2:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(-1 * 1 + 1 * 0 + 0.5 * 1) = f(-0.5) = 0; logo s_{out} = t$ (18)

Entrada 3:

$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(-1 * 1 + 1 * 1 + 0.5 * 0) = f(0) = 0; logo s_{out} = t$ (19)

Entrada 4:

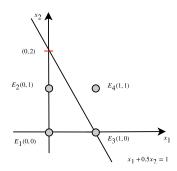
$$s_{out} = f(w_0 x_0 + w_1 x_1 + w_2 x_2)$$

= $f(-1 * 1 + 1 * 1 + 0.5 * 1) = f(0.5) = 1; logo s_{out} = t$ (20)

Logo temos o resultado: $w_0 = -1, w_1 = 1, w_2 = 0.5$

b)

Esboçando a reta $x_1 * 1 + x_2 * 0.5 = 1$ temos:



5 Derivadas

13- Seja $x,y\in\mathbb{R},\,\mathbf{x}\in\mathbb{R}^n$ e $\mathbf{y}\in\mathbb{R}^m$ de forma que:

$$\frac{\partial y}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y}{\partial x_1} \\ \frac{\partial y}{\partial x_2} \\ \vdots \\ \frac{\partial y}{\partial x_n} \end{bmatrix} \quad \frac{\partial \mathbf{y}}{\partial x} = \begin{bmatrix} \frac{\partial y_1}{\partial x} \frac{\partial y_2}{\partial x} \dots \frac{\partial y_m}{\partial x} \end{bmatrix}$$

e

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial \mathbf{y}}{\partial x_1} \\ \frac{\partial \mathbf{y}}{\partial x_2} \\ \vdots \\ \frac{\partial \mathbf{y}}{\partial x_3} \end{bmatrix} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} \frac{\partial y_2}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_1} \\ \frac{\partial y_1}{\partial x_2} \frac{\partial y_2}{\partial x_2} & \cdots & \frac{\partial y_m}{\partial x_2} \\ \vdots \\ \frac{\partial y_n}{\partial x_n} \frac{\partial y_2}{\partial x_n} & \cdots & \frac{\partial y_m}{\partial x_n} \end{bmatrix}$$

Assuma que $\mathbf{y}=f(\mathbf{u})$ e $\mathbf{u}=g(\mathbf{x})$, escreva a derivada (usando a regra da cadeia) para $\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$

- 14- Seja $\mathbf{X} \in \mathbb{R}^{m \times n}, \ \mathbf{w} \in \mathbb{R}^n, \ \mathbf{y} \in \mathbb{R}^m$ e $z = \|\mathbf{X}\mathbf{w} \mathbf{y}\|^2$, calcule $\frac{\partial z}{\partial \mathbf{w}}$.
- **15-** Sejam $u, \mathbf{x} \in \mathbb{R}^n$ (vetores colunas).
- a) Calcule a derivada de $u'\mathbf{x}$ em respeito a \mathbf{x} , ou seja: $\frac{\partial (u'\mathbf{x})}{\partial \mathbf{x}}$
- b) Calcule a derivada de $\mathbf{x}'\mathbf{x}$ em respeito a \mathbf{x} , ou seja: $\frac{\partial (\mathbf{x}'\mathbf{x})}{\partial \mathbf{x}}$

6 Regressão Linear

16- Em uma regressão linear, o valor estimado \hat{Y}_i é dado por

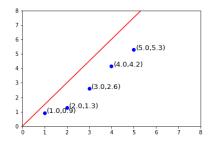
$$\hat{Y}_i = b + w_1 x_1 + \dots + w_n x_n$$

onde n é o número de features. O erro quadrático é dado por $L(\hat{Y},Y)=\sum_{i=1}^n(\hat{Y}_i-Y_i)^2$. Neste exercício, n=1, portanto $\hat{Y}_i=b+w_1x_1$.

- a) Considerando os pontos mostrados no gráfico abaixo e a reta com $w_1 = 1.5$ e b = 0, calcule o erro quadrático dessa reta.
- b) Utilize a derivada do erro quadrático para atualizar os valores de w_1 e b, encontrando uma nova reta (Dica: use uma taxa de aprendizado menor que 0.1). Qual é o erro quadrático desta nova reta?

7 Regressão Logística

17- No modelo de regressão logística com um regressor apenas: $P(Y_i=1)=p(x_i)=\frac{1}{1+\exp{(-b-w_1x_i)}}$. Deduza que a log-verossimilhança de $\theta=(b,w_1)$ no



caso do modelo logístico com um único regressor é dada por:

$$l(\theta) = b \sum_{i=1}^{n} y_i + w_1 \sum_{i=1}^{n} x_i y_i - \sum_{i} \log(1 + e^{b + w_1 x_i})$$

18- No modelo logístico com um regressor apenas, mostre que o vetor gradiente de $l(\theta)$ é dado por:

$$Dl(\theta) = \begin{bmatrix} \frac{\partial logl}{\partial b} \\ \frac{\partial logl}{\partial w_1} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^{n} y_i - p_i \\ \sum_{i=1}^{n} x_i y_i - p_i x_i \end{bmatrix}$$

onde $p_i = p(x_i)$.

19- Ainda no modelo logístico com um regressor apenas, mostre que a matriz hessiana de $l(\theta)$ é dada por:

$$Dl(\theta) = -\begin{bmatrix} \frac{\partial^2 logl}{\partial b^2} & \frac{\partial^2 logl}{\partial b\partial w_1} \\ \frac{\partial^2 logl}{\partial b\partial w_1} & \frac{\partial^2 logl}{\partial w_1^2} \end{bmatrix} = -\begin{bmatrix} \sum_{i=1}^n p_i (1-p_i) & \sum_{i=1}^n p_i (1-p_i) x_i \\ \sum_{i=1}^n p_i (1-p_i) x_i & \sum_{i=1}^n p_i (1-p_i) x_i^2 \end{bmatrix}$$

8 Newton e SGA

- **20-** Aplique duas iterações do método de newton para encontrar o ponto máximo da função $f(x)=-(x-3)^4$ para $x_0=1$.
- **21-** Utilizando a a mesma função do exercicio anterior, aplique o método do gradiente ascendente usando learning rate $\alpha=0.01$ e $x_0=1$. Compare os dois resultados.

Solução

1-
$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \frac{\partial \mathbf{y}}{\partial \mathbf{u}} \frac{\partial \mathbf{u}}{\partial \mathbf{x}}$$

2-

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{mn} \end{bmatrix} \quad \mathbf{w} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix} \quad \mathbf{Y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}$$

$$\mathbf{Xw - Y} = \begin{bmatrix} \sum_{i} x_{i1}w_{i} - y_{1} \\ \sum_{i} x_{i2}w_{i} - y_{2} \\ \vdots \\ \sum_{i} x_{im}w_{i} - y_{m} \end{bmatrix}$$

$$z = \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

$$\frac{\partial z}{\partial \mathbf{w}} = \frac{\partial \sum_{i,j} (x_{ij} w_i - y_j)^2}{\partial \mathbf{w}} = \begin{bmatrix} \frac{\partial z}{\partial w_1} \\ \frac{\partial z}{\partial w_2} \\ \vdots \\ \frac{\partial z}{\partial w_n} \end{bmatrix} \begin{bmatrix} 2 \sum_{ij} (x_{ij} w_i - y_j) \sum_j x_{1j} \\ 2 \sum_{ij} (x_{ij} w_i - y_j) \sum_j x_{2j} \\ \vdots \\ 2 \sum_{ij} (x_{ij} w_i - y_j) \sum_j x_{mj} \end{bmatrix}$$

3-

a) A derivada de $u'\mathbf{x} = \sum_{i=1}^n u_i x_i$ em respeito a \mathbf{x} :

$$\frac{\partial \sum_{i=1}^{n} u_i x_i}{\partial x_i} = u_i \Rightarrow \frac{\partial u' \mathbf{x}}{\partial \mathbf{x}} = (u_1, \dots, u_n) = u'$$

b) A derivada de $\mathbf{x}'\mathbf{x} = \sum_{i=1}^{n} x_i^2$ em respeito a \mathbf{x} :

$$\frac{\partial \sum_{i=1}^{n} x_i^2}{\partial x_i} = 2x_i \Rightarrow \frac{\partial \mathbf{x}' \mathbf{x}}{\partial \mathbf{x}} = (2\mathbf{x}_1, \dots, 2\mathbf{x}_n) = 2\mathbf{x}'$$

4-

a)

$$(1.5 - 0.9)^2 + (3 - 1.3)^2 + (4.5 - 2.6)^2 + (6 - 4.2)^2 + (7.5 - 5.3)^2 = 14.94$$

b)
$$\frac{\partial L}{\partial b} = 2\sum_{i=1}^{n} (b + w_1 x_i - Y_i) = 2nb + 2\sum_{i=1}^{n} (w_1 x_i - Y_i)$$

$$\frac{\partial L}{\partial w_1} = 2\sum_{i=1}^n \left((b + w_1 x_i - Y_i) x_i \right) = 2b\sum_{i=1}^n x_i + 2\sum_{i=1}^n (w_1 x_i^2 - Y_i x_i)$$

Colocando a taxa de aprendizado $\alpha=0.01$

$$\begin{bmatrix} w^* \\ b^* \end{bmatrix} = \begin{bmatrix} 1.5 \\ 0 \end{bmatrix} - \alpha \begin{bmatrix} 2 \sum_{i=1}^{n} (1.5x_i^2 - Y_i x_i) \\ 2 \sum_{i=1}^{n} (1.5x_i - Y_i) \end{bmatrix} = \begin{bmatrix} 0.942 \\ -0.164 \end{bmatrix}$$

$$L = (0.78 - 0.9)^2 + (1.72 - 1.3)^2 + (2.66 - 2.6)^2 + (3.6 - 4.2)^2 + (4.55 - 5.3)^2 = 1.117$$

$$\begin{split} &l(\theta) = log\left(\prod_{i=1}^{n} \mathbb{P}(Y_i = y_i)\right) \\ &= log\left(\prod_{i=1}^{n} \mathbb{P}(Y_i = y_i)\right) \\ &= log\left(\prod_{i=1}^{n} p(x_i)^{y_i}(1 - p(x_i))^{1 - y_i}\right) \\ &= \sum_{i=1}^{n} log(p(x_i)^{y_i}(1 - p(x_i))^{1 - y_i}) \\ &= \sum_{i=1}^{n} log(p(x_i)^{y_i}) + \sum_{i=1}^{n} log((1 - p(x_i))^{1 - y_i}) \\ &= \sum_{i=1}^{n} y_i log(p(x_i)) + \sum_{i=1}^{n} (1 - y_i) log(1 - p(x_i)) \\ &= \sum_{i=1}^{n} y_i log\left(\frac{1}{1 + exp(-b - w_1x_i)}\right) + \sum_{i=1}^{n} (1 - y_i) log\left(1 - \frac{1}{1 + exp(-b - w_1x_i)}\right) \\ &= \sum_{i=1}^{n} y_i log\left(\frac{exp(b + w_1x_i)}{1 + exp(b + w_1x_i)}\right) + \sum_{i=1}^{n} (1 - y_i) log\left(\frac{1}{1 + exp(b + w_1x_i)}\right) \\ &= \sum_{i=1}^{n} y_i log(exp(b + w_1x_i)) - \sum_{i=1}^{n} y_i log(1 + exp(b + w_1x_i)) + \sum_{i=1}^{n} (1 - y_i) log\left(\frac{1}{1 + exp(b + w_1x_i)}\right) \\ &= \sum_{i=1}^{n} y_i log(exp(b + w_1x_i)) - \sum_{i=1}^{n} y_i log(1 + exp(b + w_1x_i)) - \sum_{i=1}^{n} (1 - y_i) log(1 + exp(b + w_1x_i)) \\ &= \sum_{i=1}^{n} y_i (b + w_1x_i) - \sum_{i=1}^{n} y_i log(1 + exp(b + w_1x_i)) - \sum_{i=1}^{n} (1 - y_i) log(1 + exp(b + w_1x_i)) \\ &= b\sum_{i=1}^{n} y_i + w_1 \sum_{i=1}^{n} y_i x_i - \sum_{i=1}^{n} y_i log(1 + exp(b + w_1x_i)) - \sum_{i=1}^{n} (1 - y_i) log(1 + exp(b + w_1x_i)) \\ &= b\sum_{i=1}^{n} y_i + w_1 \sum_{i=1}^{n} y_i x_i - \sum_{i=1}^{n} log(1 + exp(b + w_1x_i)) - \sum_{i=1}^{n} (1 - y_i) log(1 + exp(b + w_1x_i)) \end{aligned}$$

$$\begin{split} \frac{\partial l(\theta)}{\partial b} &= \frac{\partial}{\partial b} \left(b \sum_{i=1}^n y_i + w_1 \sum_{i=1}^n y_i x_i - \sum_{i=1}^n \log(1 + \exp(b + w_1 x_i)) \right) \\ &= \frac{\partial}{\partial b} \left(b \sum_{i=1}^n y_i - \sum_{i=1}^n \log(1 + \exp(b + w_1 x_i)) \right) \\ &= \sum_{i=1}^n y_i - \sum_{i=1}^n \frac{\partial}{\partial b} (\log(1 + \exp(b + w_1 x_i))) \\ &= \sum_{i=1}^n y_i - \sum_{i=1}^n \frac{\partial}{\partial b} (1 + \exp(b + w_1 x_i)) \\ &= \sum_{i=1}^n y_i - \sum_{i=1}^n \frac{\exp(b + w_1 x_i)}{1 + \exp(b + w_1 x_i)} \\ &= \sum_{i=1}^n y_i - \sum_{i=1}^n p_i \\ &= \sum_{i=1}^n (y_i - p_i) \\ &= \frac{\partial}{\partial w_1} \left(b \sum_{i=1}^n y_i + w_1 \sum_{i=1}^n y_i x_i - \sum_{i=1}^n \log(1 + \exp(b + w_1 x_i)) \right) \\ &= \frac{\partial}{\partial w_1} \left(w_1 \sum_{i=1}^n y_i x_i - \sum_{i=1}^n \log(1 + \exp(b + w_1 x_i)) \right) \\ &= \sum_{i=1}^n y_i x_i - \sum_{i=1}^n \frac{\partial}{\partial w_1} (\log(1 + \exp(b + w_1 x_i))) \\ &= \sum_{i=1}^n y_i x_i - \sum_{i=1}^n \frac{\partial}{\partial w_1} (1 + \exp(b + w_1 x_i)) \\ &= \sum_{i=1}^n y_i x_i - \sum_{i=1}^n \frac{x_i \exp(b + w_1 x_i)}{1 + \exp(b + w_1 x_i)} \\ &= \sum_{i=1}^n y_i x_i - \sum_{i=1}^n x_i p_i \\ &= \sum_{i=1}^n (y_i x_i - x_i p_i) \end{split}$$

$$\begin{split} \frac{\partial^2 l(\theta)}{\partial b^2} &= \frac{\partial}{\partial b} \left(\sum_{i=1}^n y_i - \sum_{i=1}^n p_i \right) \\ &= \frac{\partial}{\partial b} \left(\sum_{i=1}^n y_i - \sum_{i=1}^n \frac{1}{1 + exp(-b - w_1 x_i)} \right) \\ &= -\sum_{i=1}^n \frac{\partial}{\partial b} \left(\frac{1}{1 + exp(-b - w_1 x_i)} \right) \\ &= -\sum_{i=1}^n \left(-\frac{-exp(-b - w_1 x_i)}{(1 + exp(-b - w_1 x_i))^2} \right) \\ &= -\sum_{i=1}^n \left(\frac{exp(-b - w_1 x_i)}{(1 + exp(-b - w_1 x_i))^2} \right) \\ &= -\sum_{i=1}^n \left(\frac{exp(-b - w_1 x_i)}{1 + exp(-b - w_1 x_i)} \frac{1}{1 + exp(-b - w_1 x_i)} \right) \\ &= -\sum_{i=1}^n \left(\frac{1}{1 + exp(b + w_1 x_i)} \frac{1}{1 + exp(-b - w_1 x_i)} \right) \\ &= -\sum_{i=1}^n (1 - p_i) p_i \end{split}$$

$$\begin{split} \frac{\partial^2 l(\theta)}{\partial b \partial w_1} &= \frac{\partial^2 l(\theta)}{\partial w_1 \partial b} = \frac{\partial}{\partial w_1} \left(\sum_{i=1}^n y_i - \sum_{i=1}^n p_i \right) \\ &= \frac{\partial}{\partial w_1} \left(\sum_{i=1}^n y_i - \sum_{i=1}^n \frac{1}{1 + exp(-b - w_1 x_i)} \right) \\ &= -\sum_{i=1}^n \frac{\partial}{\partial w_1} \left(\frac{1}{1 + exp(-b - w_1 x_i)} \right) \\ &= -\sum_{i=1}^n \left(-\frac{-x_i exp(-b - w_1 x_i)}{(1 + exp(-b - w_1 x_i))^2} \right) \\ &= -\sum_{i=1}^n \left(\frac{x_i exp(-b - w_1 x_i)}{(1 + exp(-b - w_1 x_i))^2} \right) \\ &= -\sum_{i=1}^n \left(\frac{x_i exp(-b - w_1 x_i)}{1 + exp(-b - w_1 x_i)} \frac{1}{1 + exp(-b - w_1 x_i)} \right) \\ &= -\sum_{i=1}^n \left(x_i \frac{1}{1 + exp(b + w_1 x_i)} \frac{1}{1 + exp(-b - w_1 x_i)} \right) \\ &= -\sum_{i=1}^n x_i (1 - p_i) p_i \end{split}$$

$$\frac{\partial^2 l(\theta)}{\partial w_1^2} &= \frac{\partial}{\partial w_1} \left(\sum_{i=1}^n y_i x_i - \sum_{i=1}^n x_i p_i \right) \\ &= \frac{\partial}{\partial w_1} \left(-\sum_{i=1}^n x_i p_i \right) \\ &= \frac{\partial}{\partial w_1} \left(-\sum_{i=1}^n x_i p_i \right) \\ &= \frac{\partial}{\partial w_1} \left(-\sum_{i=1}^n x_i p_i \right) \\ &= -\sum_{i=1}^n x_i \frac{x_i exp(-b - w_1 x_i)}{(1 + exp(-b - w_1 x_i))^2} \\ &= -\sum_{i=1}^n x_i x_i \frac{exp(-b - w_1 x_i)}{1 + exp(-b - w_1 x_i)} \frac{1}{1 + exp(-b - w_1 x_i)} \\ &= -\sum_{i=1}^n x_i^2 (1 - p_i) p_i \end{split}$$

8- Jupyter notebook

9-

Seja $x_0 = 1$ e f(x) e suas derivadas:

$$f(x) = -(x-3)^4$$

$$f'(x) = -4(x-3)^3$$

$$f''(x) = -12(x-3)^2$$
(21)

Utilizando método de Newton: $x_{n+1} = x_n - \frac{f^{'}(x_n)}{f^{''}(x_n)}$

• Para
$$n = 0$$
 e $x_0 = 1$
 $x_1 = x_0 - \frac{f'(x_0)}{f''(x_0)} = 1.66$

• Para
$$n = 1$$
 e $x_1 = 1.66$
 $x_2 = x_1 - \frac{f'(x_1)}{f''(x_1)} = 2.11$

• Para
$$n = 2$$
 e $x_1 = 2.11$
 $x_3 = x_2 - \frac{f'(x_2)}{f''(x_2)} = 2.407$

10-

Utilizando método do Gradient Ascendente: $x_{n+1} = x_n + \alpha * f'(x_n)$, onde $\alpha = 0.01$

• Para
$$n = 0$$
 e $x_0 = 1$
 $x_1 = x_0 + \alpha * f'(x_0) = 1.32$

• Para
$$n = 1$$
 e $x_1 = 1.32$
 $x_2 = x_1 + \alpha * f'(x_1) = 1.509$

• Para
$$n = 2$$
 e $x_2 = 1.509$
 $x_3 = x_2 + \alpha * f'(x_2) = 1.64$