Convolutional Neural Networks

Uma camada de uma CNN

Exemplo de uma camada

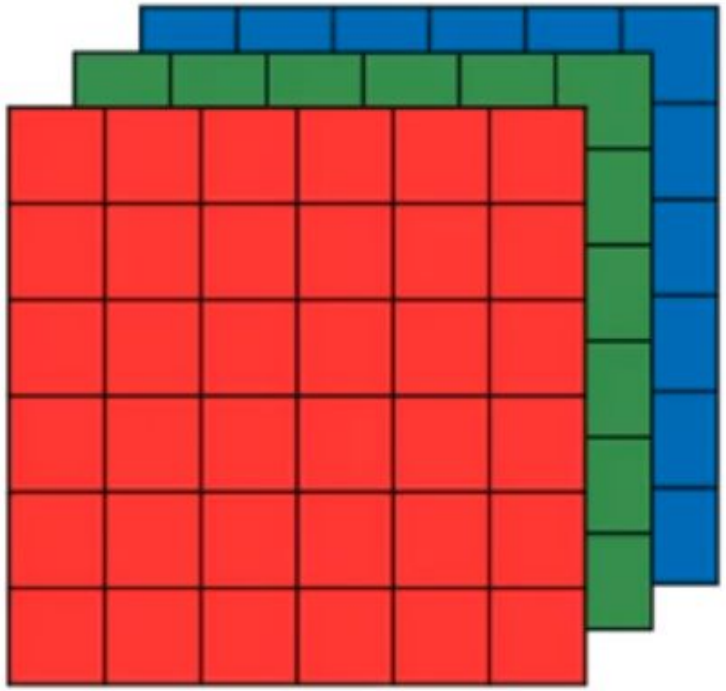

6 x 6 x 3

*

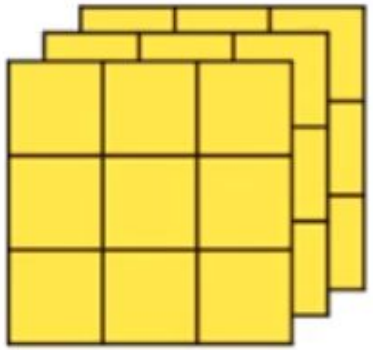

3 x 3 x 3

*

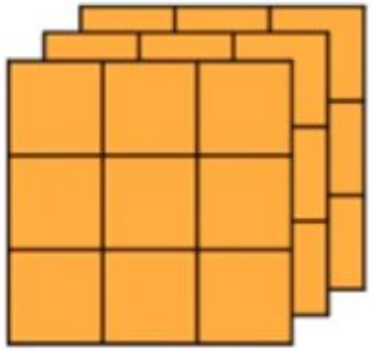

3 x 3 x 3

Exemplo de uma camada

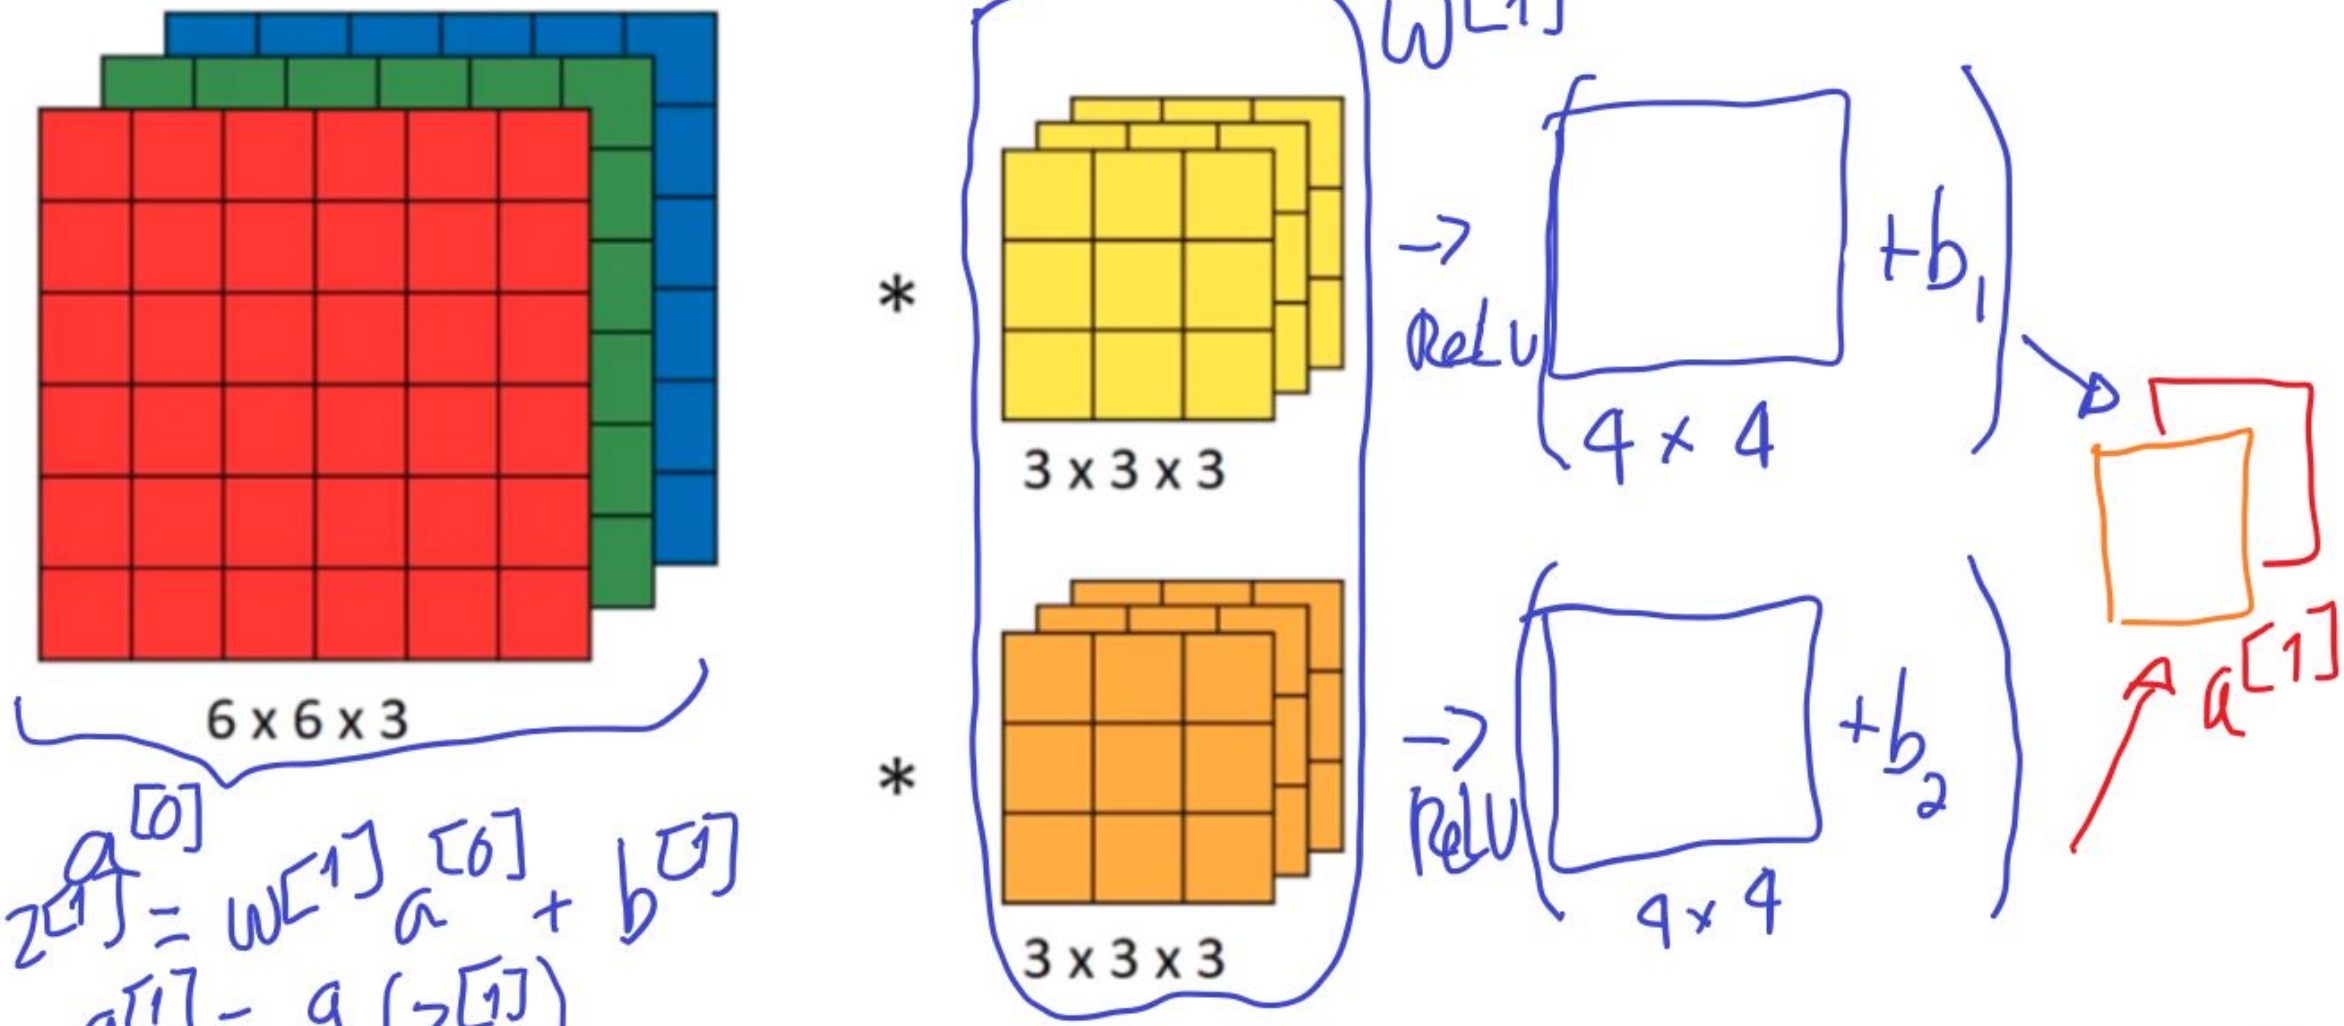

$a^{[0]}$

$z^{[1]} = W^{[1]} a^{[0]} + b^{[1]}$

$a^{[1]} = g(z^{[1]})$

Número de parâmetros em uma camada

Se você tem 10 filtros 3x3x3 em uma camada de uma rede neural, quantos parâmetros essa camada tem?

Sumário da notação

Se a camada **l** é uma camada convolucional:

$f^{[l]}$ = tamanho do filtro

$p^{[l]}$ = padding

$s^{[l]}$ = stride

$n_c^{[l]}$ = número de filtros

Entrada:

Saída:

Cada filtro é:

Ativações:

Pesos:

Bias:

Sumário da notação

camada l

Se a camada **l** é uma camada convolucional:

$f^{[l]}$ = tamanho do filtro

$p^{[l]}$ = padding

$s^{[l]}$ = stride

$n_c^{[l]}$ = número de filtros

Entrada: $n_H^{[l-1]} \times n_W^{[l-1]} \times n_C^{[l-1]}$

Saída: $n_H^{[l]} \times n_W^{[l]} \times n_C^{[l]}$

$\hookrightarrow n_H^{[l]} = \frac{n^{[l-1]} + 2p^{[l]} - f^{[l]}}{s^{[l]}} + 1$

Cada filtro é: $f^{[l]} \times f^{[l]} \times n_C^{[l-1]}$

Ativações: $a^{[l]} \Rightarrow n_H^{[l]} \times n_W^{[l]} \times n_C^{[l]}$

Pesos: $f^{[l]} \rightarrow f^{[l]} \times n_C^{[l-1]} \times n_C^{[l]}$

Bias: $n_C^{[l]}$

$\hookrightarrow (1, 1, 1, n_C^{[l]})$

matriz de ativ. p/ m exemplos de treino

$A^{[l]} \rightarrow m \times n_H^{[l]} \times n_W^{[l]} \times n_C^{[l]}$

Uma camada de uma CNN

- Primeiro, convolvemos alguns filtros para uma determinada entrada
- Em seguida, adicionamos um viés a cada saída do filtro
- Por fim, obtemos o RELU do resultado

Uma camada de uma CNN

- Exemplo:

  Imagem de entrada: **6x6x3** # a0

  10 filtros: **3x3x3** # W1

  Resultado: **4x4x10** # W1a0

  Adicionar **b** (viés) com **10x1** nos levará: imagem **4x4x10** # W1a0 + b

  Aplicar **RELU** nos levará: imagem **4x4x10** # A1 = RELU (W1a0 + b)

  No último resultado **p = 0**, **s = 1**

  O número de parâmetros aqui é: **(3x3x3x10) + 10 = 280**

- **Dica:** não importa o tamanho da entrada, o número de parâmetros é o mesmo se o tamanho do filtro for o mesmo
  - Isso torna menos propenso a overfitting

Se a camada `l` for uma camada `conv`

f[l] = filter size

p[l] = padding # Default is zero

s[l] = stride

nc[l] = number of filters

Input: n[l-1] x n[l-1] x nc[l-1] **Or** nH[l-1] x nW[l-1] x nc[l-1]

Output: n[l] x n[l] x nc[l] **Or** nH[l] x nW[l] x nc[l]

Where n[l] = (n[l-1] + 2p[l] - f[l] / s[l]) + 1

Each filter is: f[l] x f[l] x nc[l-1]

Activations: a[l] is nH[l] x nW[l] x nc[l]

A[l] is m x nH[l] x nW[l] x nc[l] # In batch or minbatch training

Weights: f[l] * f[l] * nc[l-1] * nc[l]

bias: (1, 1, 1, nc[l])

Convolutional Neural Networks

Um exemplo simples de CNN

Exemplo de ConvNet

Exemplo de ConvNet

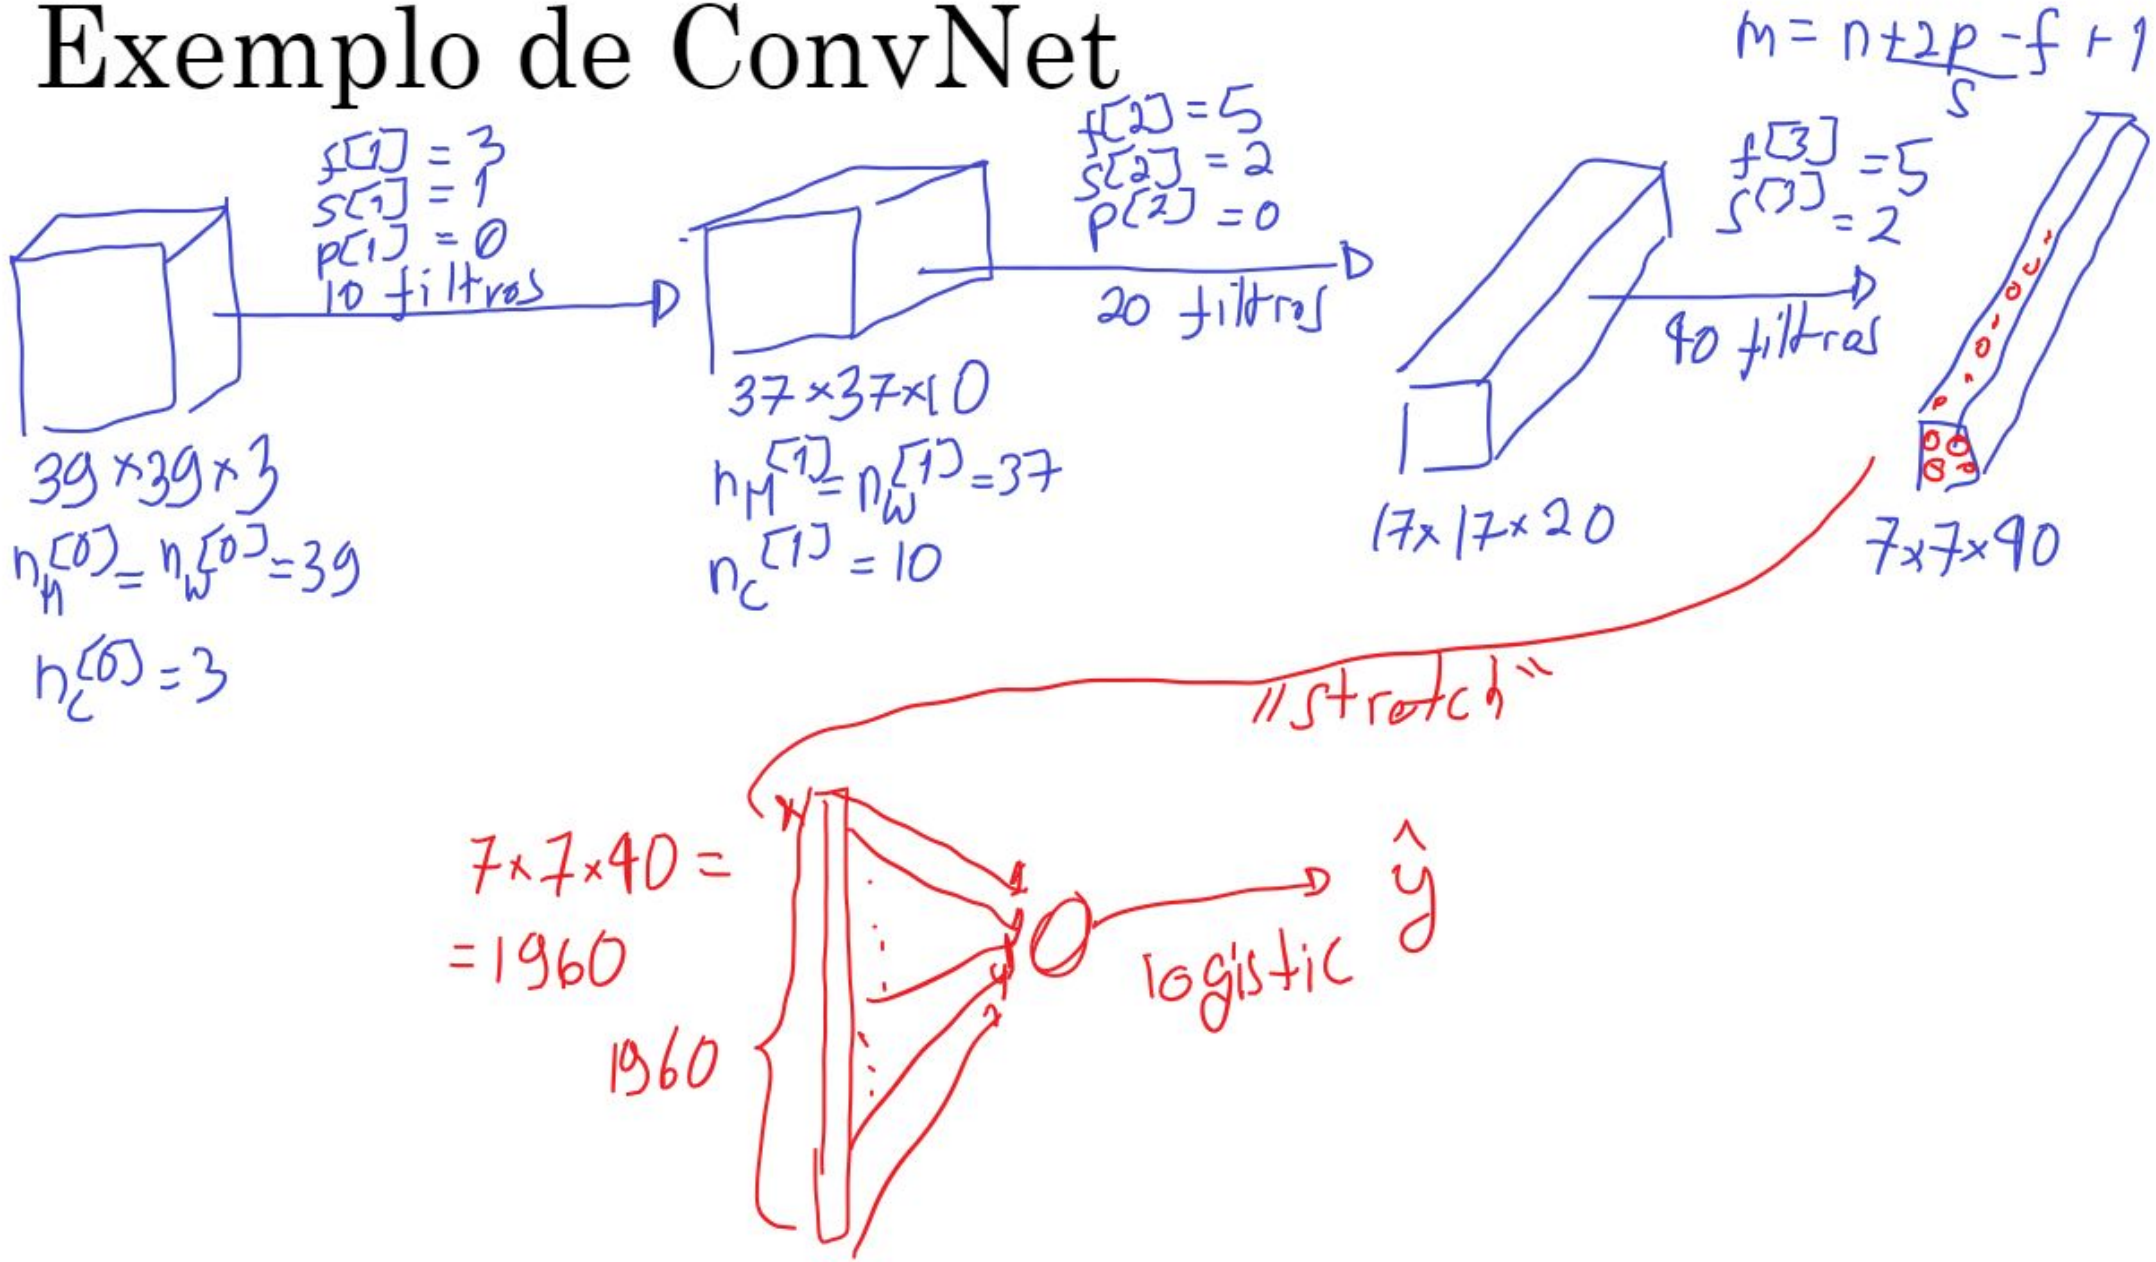

Um grande exemplo:

- Entrada: imagens são **a0 = 39x39x3**
  - **n0 = 39** e **nc0 = 3**

- Primeira camada (camada **Conv**):
  - **f1 = 3**, **s1 = 1**, e **p1 = 0**
  - número de filtros = **10**
  - Então, as saídas são: **a1 = 37x37x10**
    - **n1 = 37** e **nc1 = 10**

- Segunda camada (camada **Conv**):
  - **f2 = 5**, **s2 = 2**, **p2 = 0**
  - número de filtros = **20**
  - As saídas são **a2 = 17x17x20**
    - **n2 = 17**, **nc2 = 20**
  - **Dica:** o encolhimento é muito mais rápido, pois o *stride* é **2**

- Terceira camada (camada **Conv**):
  - **f3 = 5**, **s3 = 2**, **p3 = 0**
  - número de filtros = **40**
  - As saídas são **a3 = 7x7x40**
    - **n3 = 7**, **nc3 = 40**

- Quarta camada (Softmax todo conectado)
  - **a3 = 7x7x40 = 1960** como um vetor

- Imagens estão ficando cada vez menor após cada camada.

Tipos de camadas em uma rede convolucional:

- Convolucional (Conv)

- Pooling (Pool)

- Toda conectada (*Fully connected*)

Convolutional Neural Networks

Camadas de *pooling*

Camada de *pooling*: *Max pooling*

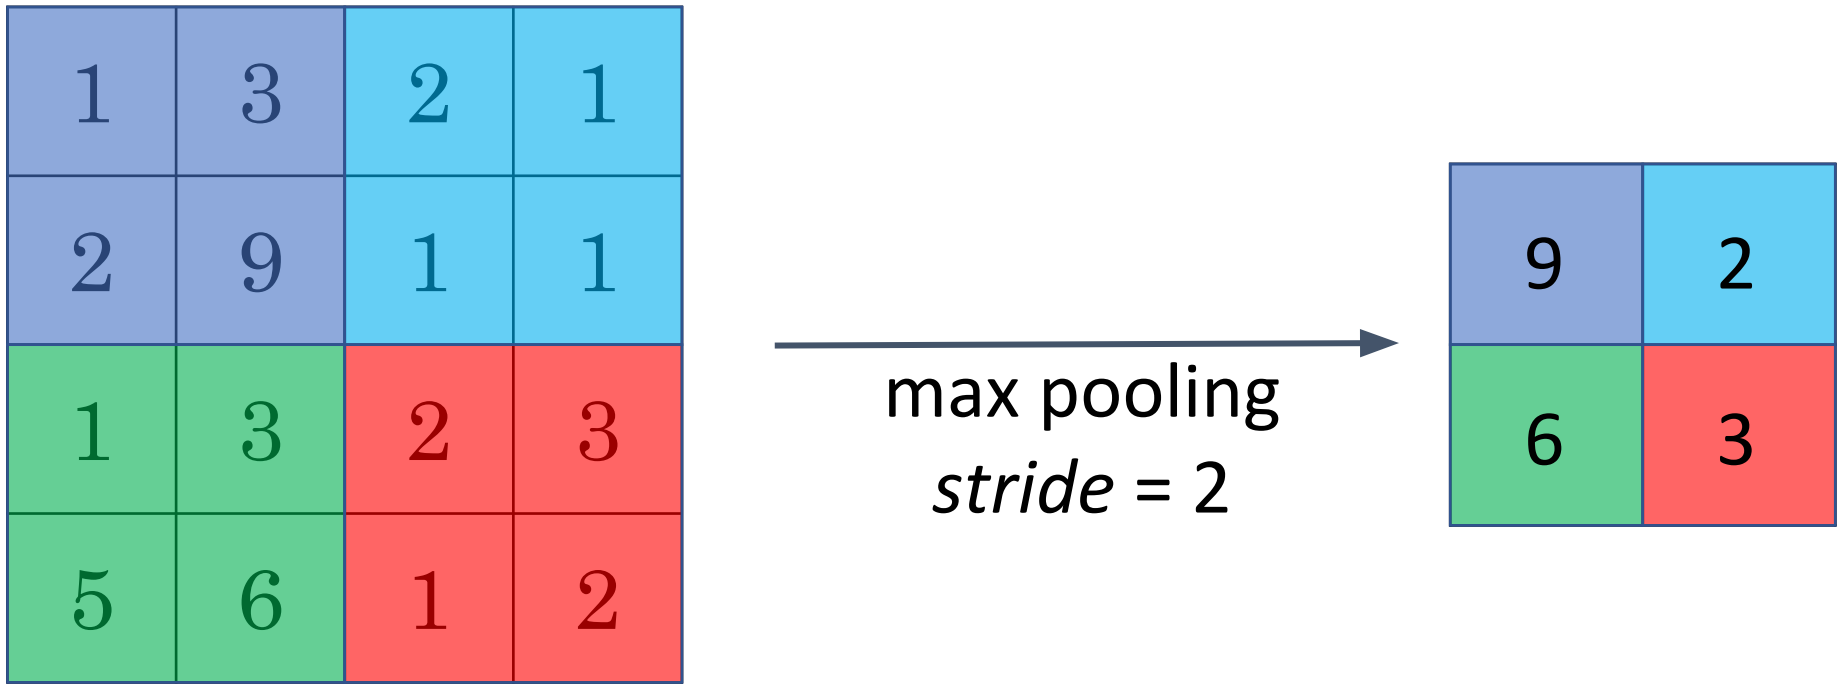

Camada de *pooling*: *Max pooling*

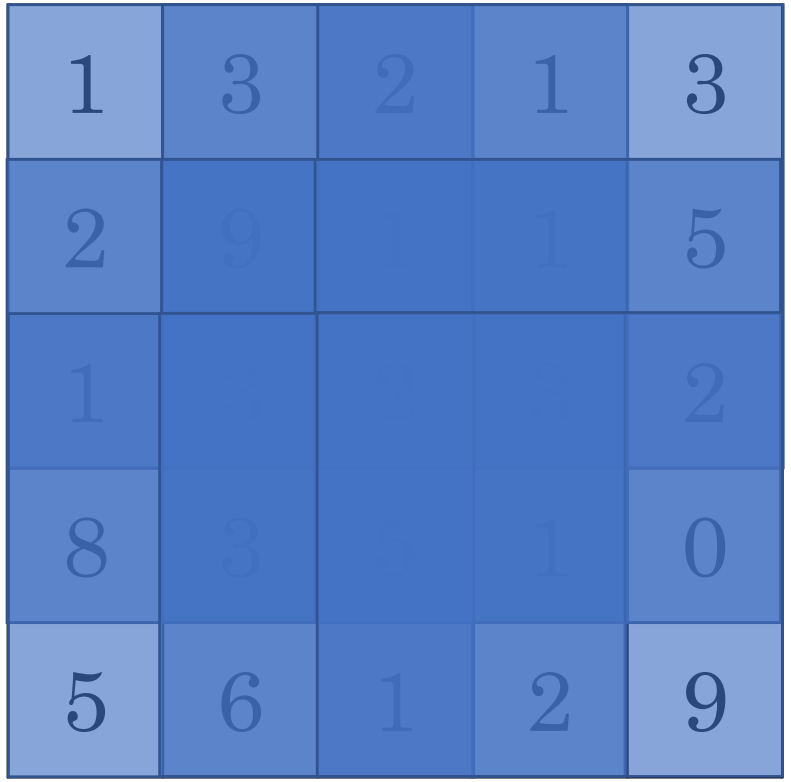

max pooling
stride = 1

9	9	5
9	9	5
8	6	9

Camada de *pooling*: *Average pooling*

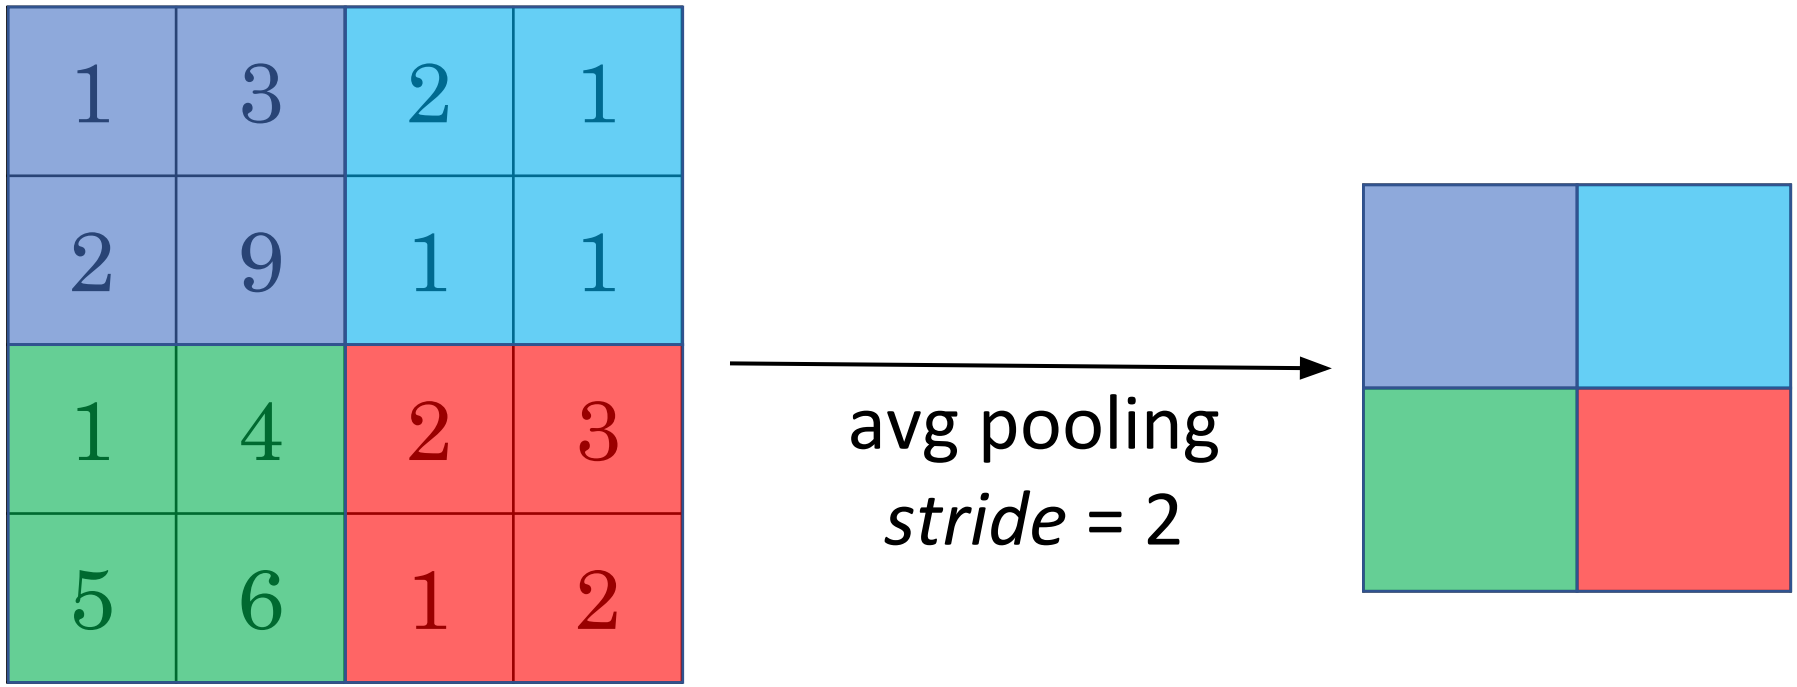

Camada de *pooling*: *Average pooling*

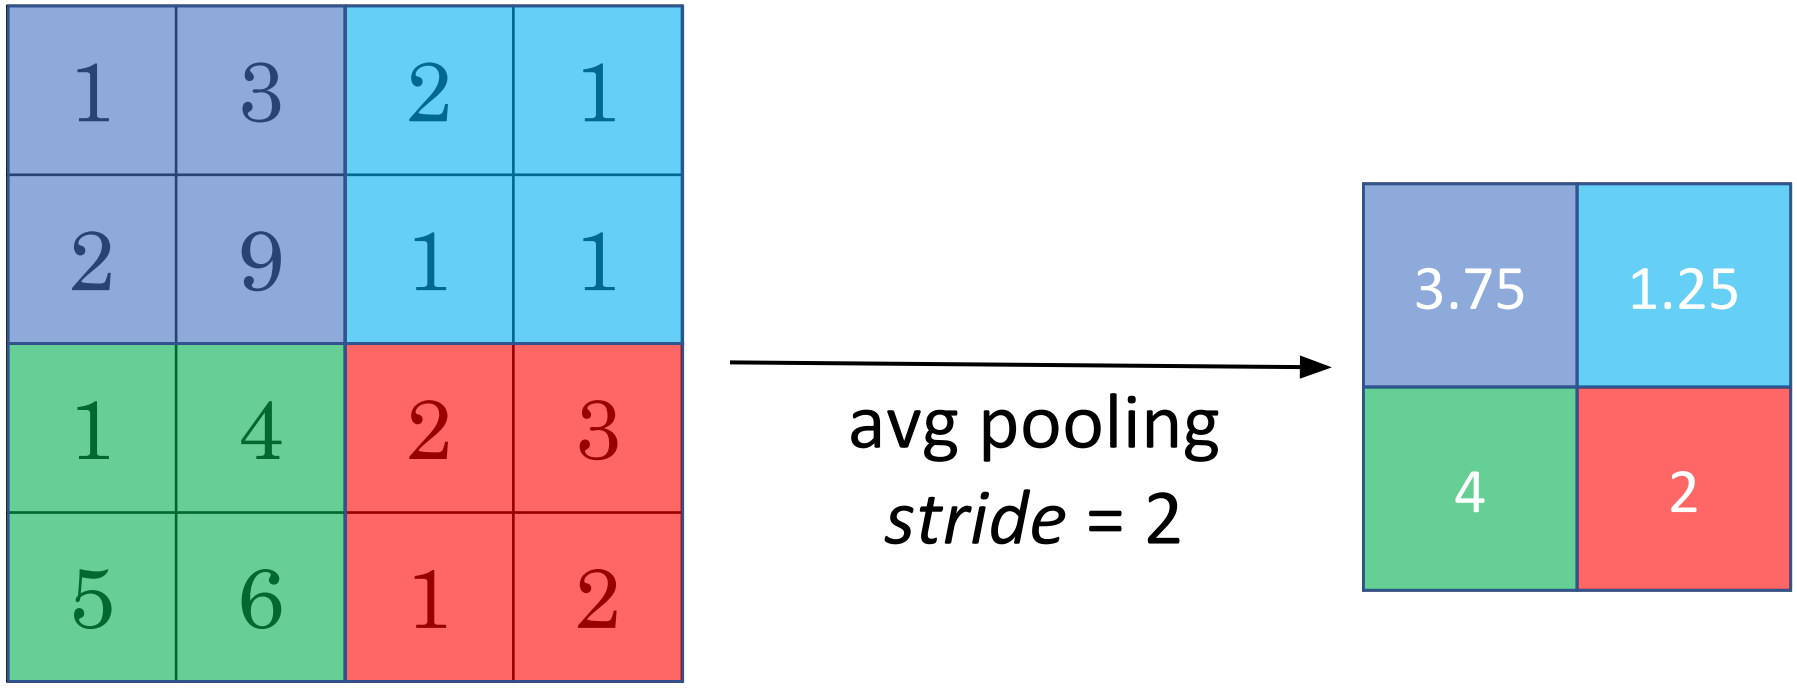

Camada de *pooling*: *Average pooling*

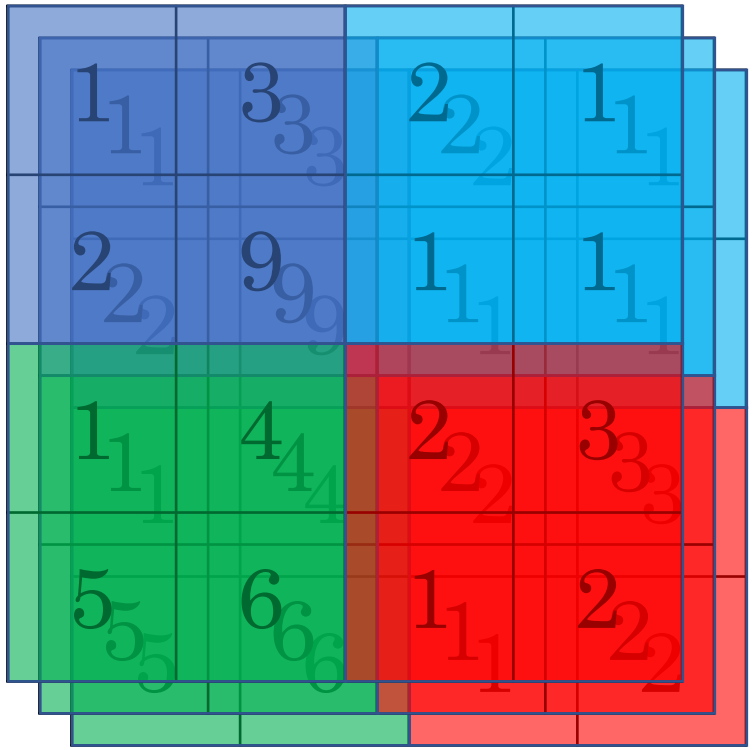

$n_c = 3$

avg pooling
stride = 2

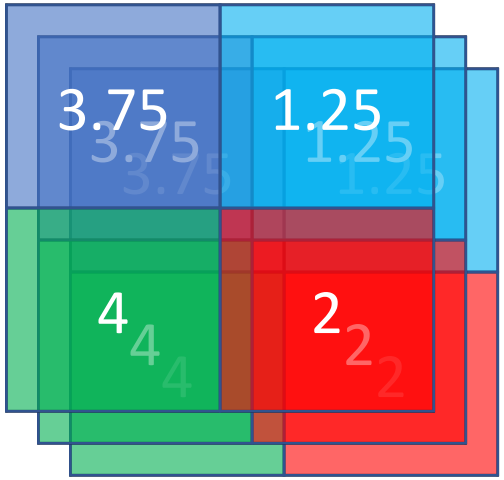

$n_c = 3$

Camadas de *pooling*

- Além das camadas **conv**, as CNNs geralmente usam camadas de pooling para
  - reduzir o tamanho das entradas
  - acelerar a computação
  - tornar algumas das ***features*** que ele detecta **mais robustas**

Max *pooling*

- O ***max pooling*** está fazendo o seguinte: se *a feature* for detectada **em qualquer lugar** desse filtro, mantenha um número **alto**
- A principal razão pela qual as pessoas o estão usando é porque ele funciona bem na prática e reduz os cálculos
- Não tem parâmetros para aprender

Max *pooling*

- Exemplo de max *pooling* em entrada 3D:
- Entrada: 4x4x10
- Tamanho do max *pooling* = 2 e *stride* = 2
- Saída: 2x2x10

Average pooling

- O *average pooling* tira as médias dos valores em vez de obter os valores máximos
- O *max pooling* é usado com mais frequência do que o *average pooling* na prática
- Se o *stride* do *pooling* for igual ao tamanho, então ele aplicará o efeito de encolhimento

Sumário de *pooling*

Hiperparâmetros:

f : tamanho do filtro

s : *stride*

Max ou *average pooling*

Padding (incomum)

Convolutional Neural Networks

Outro exemplo de CNN

Exemplo de CNN

Exemplo de CNN

	shape da ativação	tamanho	# parâmetros
Entrada:	(32,32,3)	3,072	0

Exemplo de CNN

- Hiperparâmetros são **muitos**
- Para **escolher** o valor de cada um, você deve seguir a diretriz que discutiremos mais tarde ou verificar a literatura e tirar algumas ideias e números dela
- Normalmente, o tamanho da entrada **diminui** em camadas, enquanto o número de filtros **aumenta**
- Uma CNN geralmente consiste em **uma ou mais convoluções** (não apenas uma como os exemplos mostrados) seguidas por um ***pooling***
- Camadas totalmente conectadas têm a **maioria dos parâmetros**
- Para considerar o uso desses blocos juntos, você deve **procurar outros exemplos** de trabalho para obter algumas intuições

Convolutional Neural Networks

Por que convoluções?

Por que convoluções?

Por que convoluções?

10	10	10	0	0	0
10	10	10	0	0	0
10	10	10	0	0	0
10	10	10	0	0	0
10	10	10	0	0	0
10	10	10	0	0	0

*

1	0	-1
1	0	-1
1	0	-1

=

0	30	30	0
0	30	30	0
0	30	30	0
0	30	30	0

Compartilhamento de parâmetros: um detector de *features* (como um detector de borda vertical) útil em uma parte da imagem é provavelmente útil em outra parte

Esparsidade de conexões: em cada camada, cada valor de saída depende apenas de um pequeno número de entradas

Colocando tudo junto

Training set $(x^{(1)}, y^{(1)}) \ldots (x^{(m)}, y^{(m)})$.

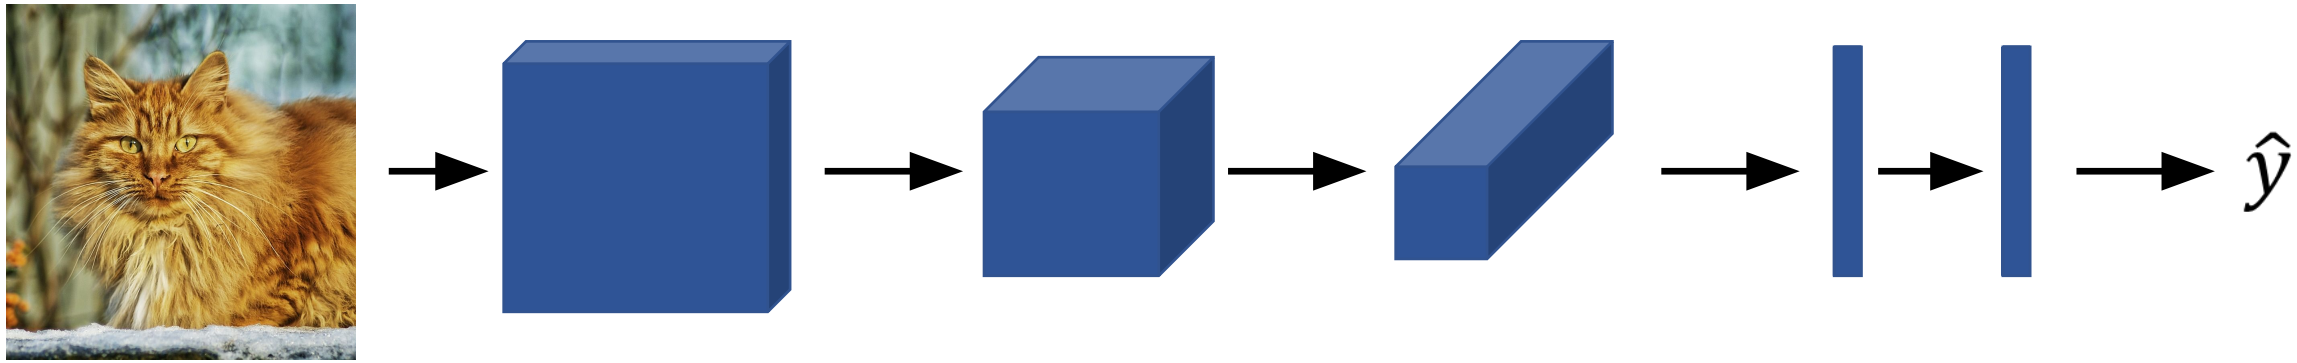

$$\text{Cost } J = \frac{1}{m} \sum_{i=1}^{m} \mathcal{L}(\hat{y}^{(i)}, y^{(i)})$$

Use o gradiente descendente para otimizar os parâmetros que reduzem **J**

Para brincar

ConvNetJS CIFAR-10 demo

Description

This demo trains a Convolutional Neural Network on the CIFAR-10 dataset in your browser, with nothing but Javascript. The state of the art on this dataset is about 90% accuracy and human performance is at about 94% (not perfect as the dataset can be a bit ambiguous). I used this python script to parse the original files (python version) into batches of images that can be easily loaded into page DOM with img tags.

This dataset is more difficult and it takes longer to train a network. Data augmentation includes random flipping and random image shifts by up to 2px horizontally and verically.

By default, in this demo we're using Adadelta which is one of per-parameter adaptive step size methods, so we don't have to worry about changing learning rates or momentum over time. However, I still included the text fields for changing these if you'd like to play around with SGD+Momentum trainer.

Report questions/bugs/suggestions to @karpathy.

http://cs.stanford.edu/people/karpathy/convnetjs/demo/cifar10.html

Links úteis

https://towardsdatascience.com/backpropagation-in-a-convolutional-layer-24c8d64d8509